Введение в инженерную деятельность

Корелин Иван

Корелин Иван

Ведущий разработчик, Т-банк

Несколько фактов обо мне

- **Ведущий разработчик Т-банк с 2022 года, разрабатываю платформу загрузки данных**
- **Пишу на Java**
- **14 лет промышленного опыта в банковском ИТ (Синара, Сбер, ВТБ, Т-банк)**
- **ктн, доцент ИРИТ-РтФ УрФУ**

  кафедра автоматизации финансовых систем и УНЦ Искусственный Интеллект

Кто такой инженер данных?

И чем он занимается

План занятия

- Наука о данных
- Разделение специализаций
- Инженер данных
- Хранилища данных

Коротко о том что изучает наука о данных

- Чем вообще занимаются в науке
- Что такое данные и информация

Варианты получения знаний:

1. Анализ «природы процесса», поиск «физического смысла» или изучение бизнес-домена явления.
2. Получение знаний из данных путём исследования статистических закономерностей в больших объемах данных.

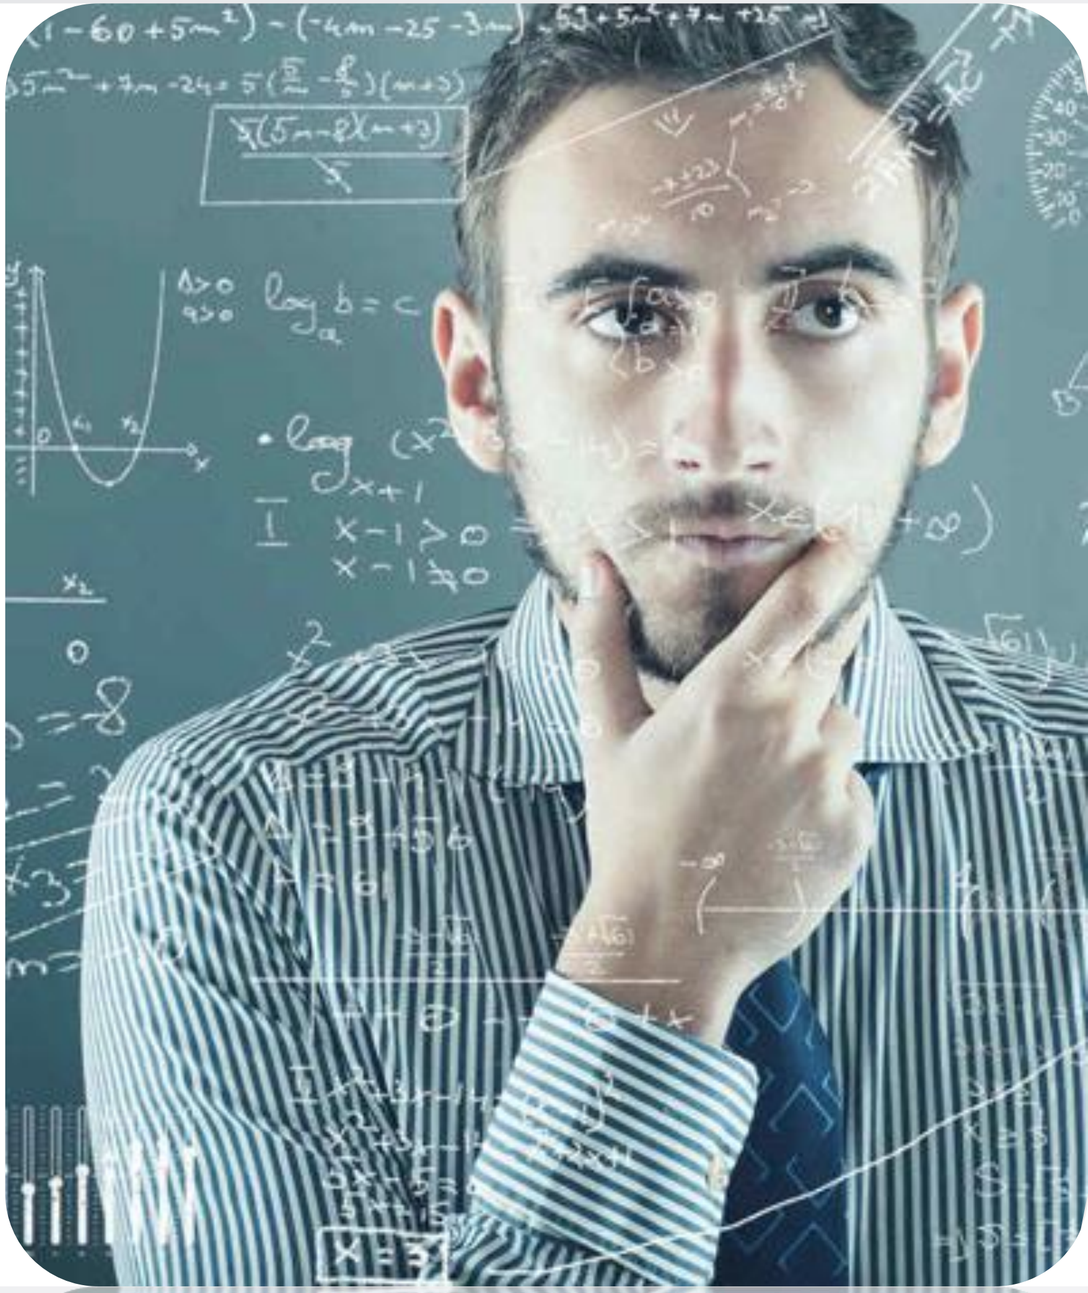

Что такое информация?

Информация - сведения независимо от формы их представления.

Несмотря на широкую распространённость, понятие информации остаётся одним из самых ***дискуссионных*** в науке, а термин может иметь различные значения в разных отраслях человеческой деятельности

Место ИИ в науке о данных

Инженеры в DS

- Зачем в науке инженеры
- Какие инженерные роли бывают

Инженер ⇄ Ученый

Если вы ***инженер*** и делаете то, что ранее **не** делали – лучше остановитесь и всё обдумайте.

Если вы ***ученый*** и делаете то, что **уже** делали ранее - лучше остановитесь и всё обдумайте.

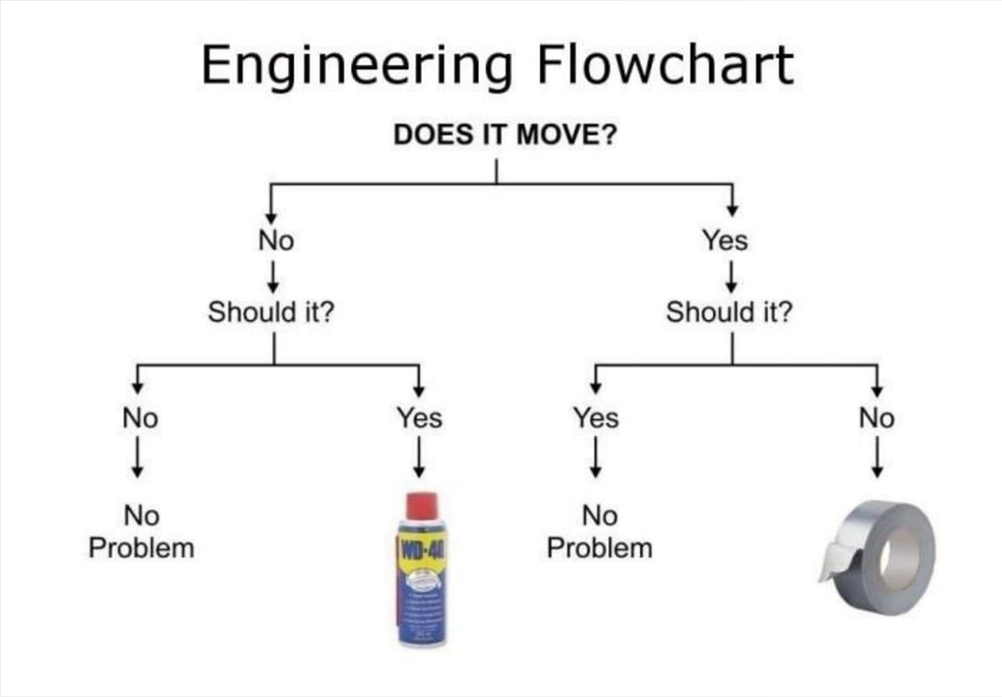

Разделение специализаций

Поскольку сфера активно развивается, работа в науке о данных активно специализируется. Появляются новые профессии, со своими тонкостями и особенностями, с разным набором компетенций и требований.

- **Data Scientist**
- **Data Analyst**
- **Data Engineer**
- **Data Steward**
- **Machine Learning Engineer**
- **Computer Vision-специалист**
- **NLP-специалист**
- **MLOps**
- **LLOps**
- **etc**

Data Engineer (DE)

- Профессия на стыке Software Development Engineer и Data science
- Ориентир на backend разработку с погружением в технологии СУБД
- Визуализация данных
- Потребители продуктов - аналитики

Data Engineer это как Software Engineer в DS

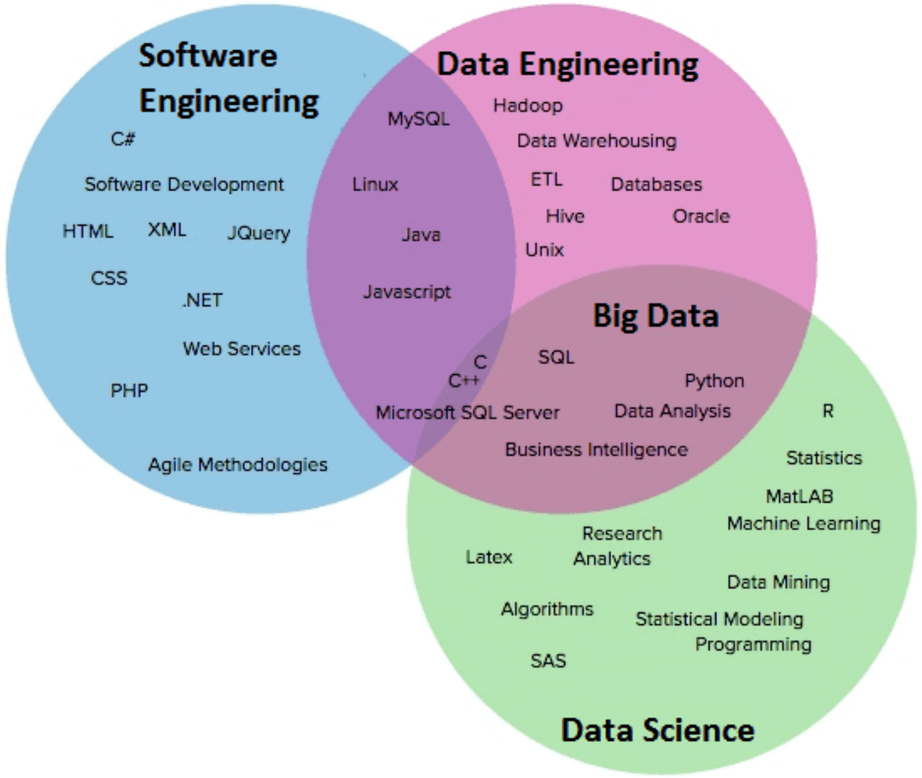

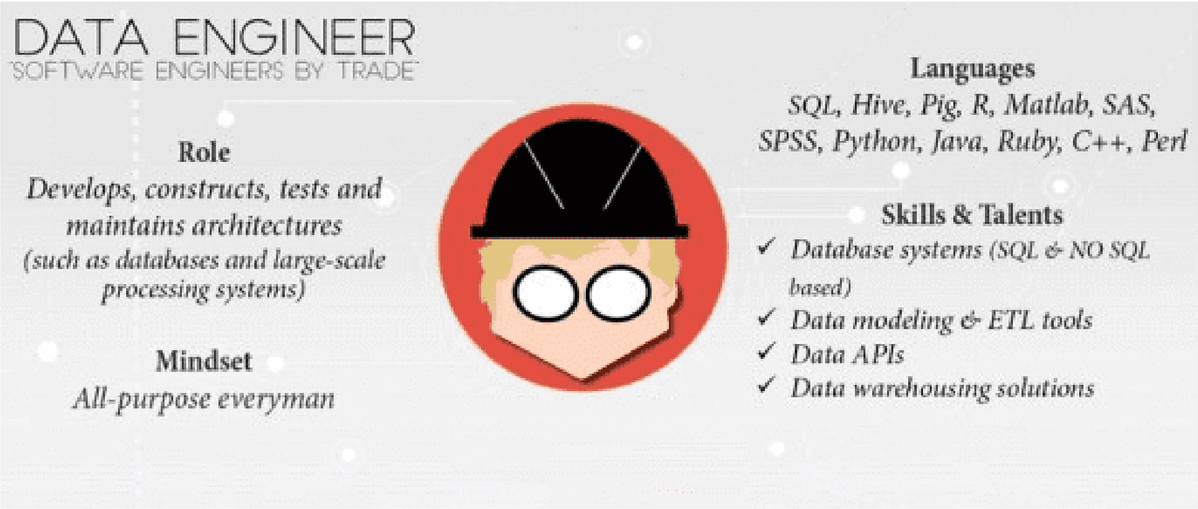

Компетенции

- **End-to-end разработка потоков данных**: понимание откуда данные берутся, как преобразуются и куда поступают.
- **ETL-процессы**: так или иначе DE участвуют в процессах извлечения(**E**xtract), преобразования(**T**ransform) и загрузки(**L**oad) данных.
- **Проектирование:** проектирует архитектуры хранения данных, сервисов и микросервисов для реализации самообслуживания владельцами и потребителями данных
- **Разработка:** Контракты данных, SQL- запросы, функции обработки (python), микросервисы (java/docker), конвейеры(airflow/k8s/spark/flink)
- **Тестирование**: умеет тестировать всё от модульных тестов и интеграции до качества данных и проверок целостности.
- **Прозрачность**: разрабатывает механизмы мониторинга и алертинга для обеспечения согласованных уровней о качестве обслуживания (SLA).

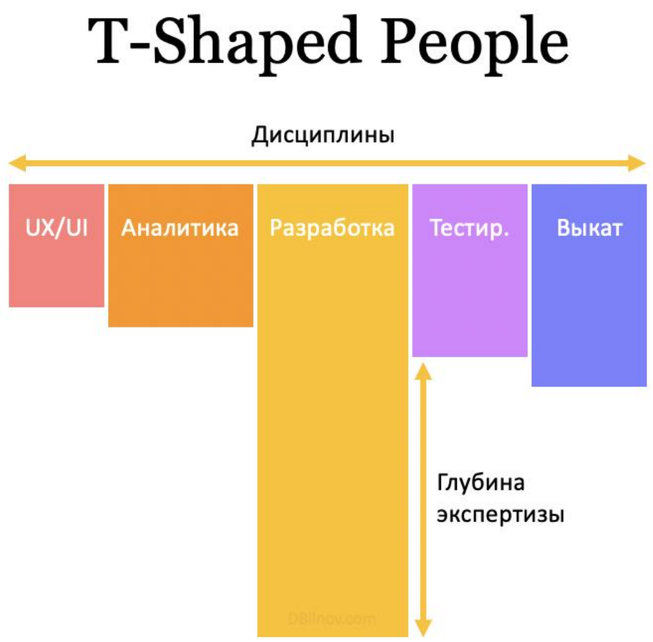

Хранилища данных

- Хранилища данных
- Озера данных
- Gartner Data Management Hype Cycle

Что такое Datawarehouse

Хранилище данных (datawarehouse) представляет собой данные, агрегированные из разных источников в единый центральный репозиторий, который унифицирует их по качеству и формату. Далее эти данные могут быть использованы в таких сферах, как data mining, искусственный интеллект, машинное обучение и бизнес-аналитика.

Витрина данных (datamart) — это часть хранилища данных, предназначенная для определенного круга пользователей в организации. Наборы данных в витрине данных часто используются в режиме реального времени для аналитики и получения практических результатов.

Что такое Datawarehouse

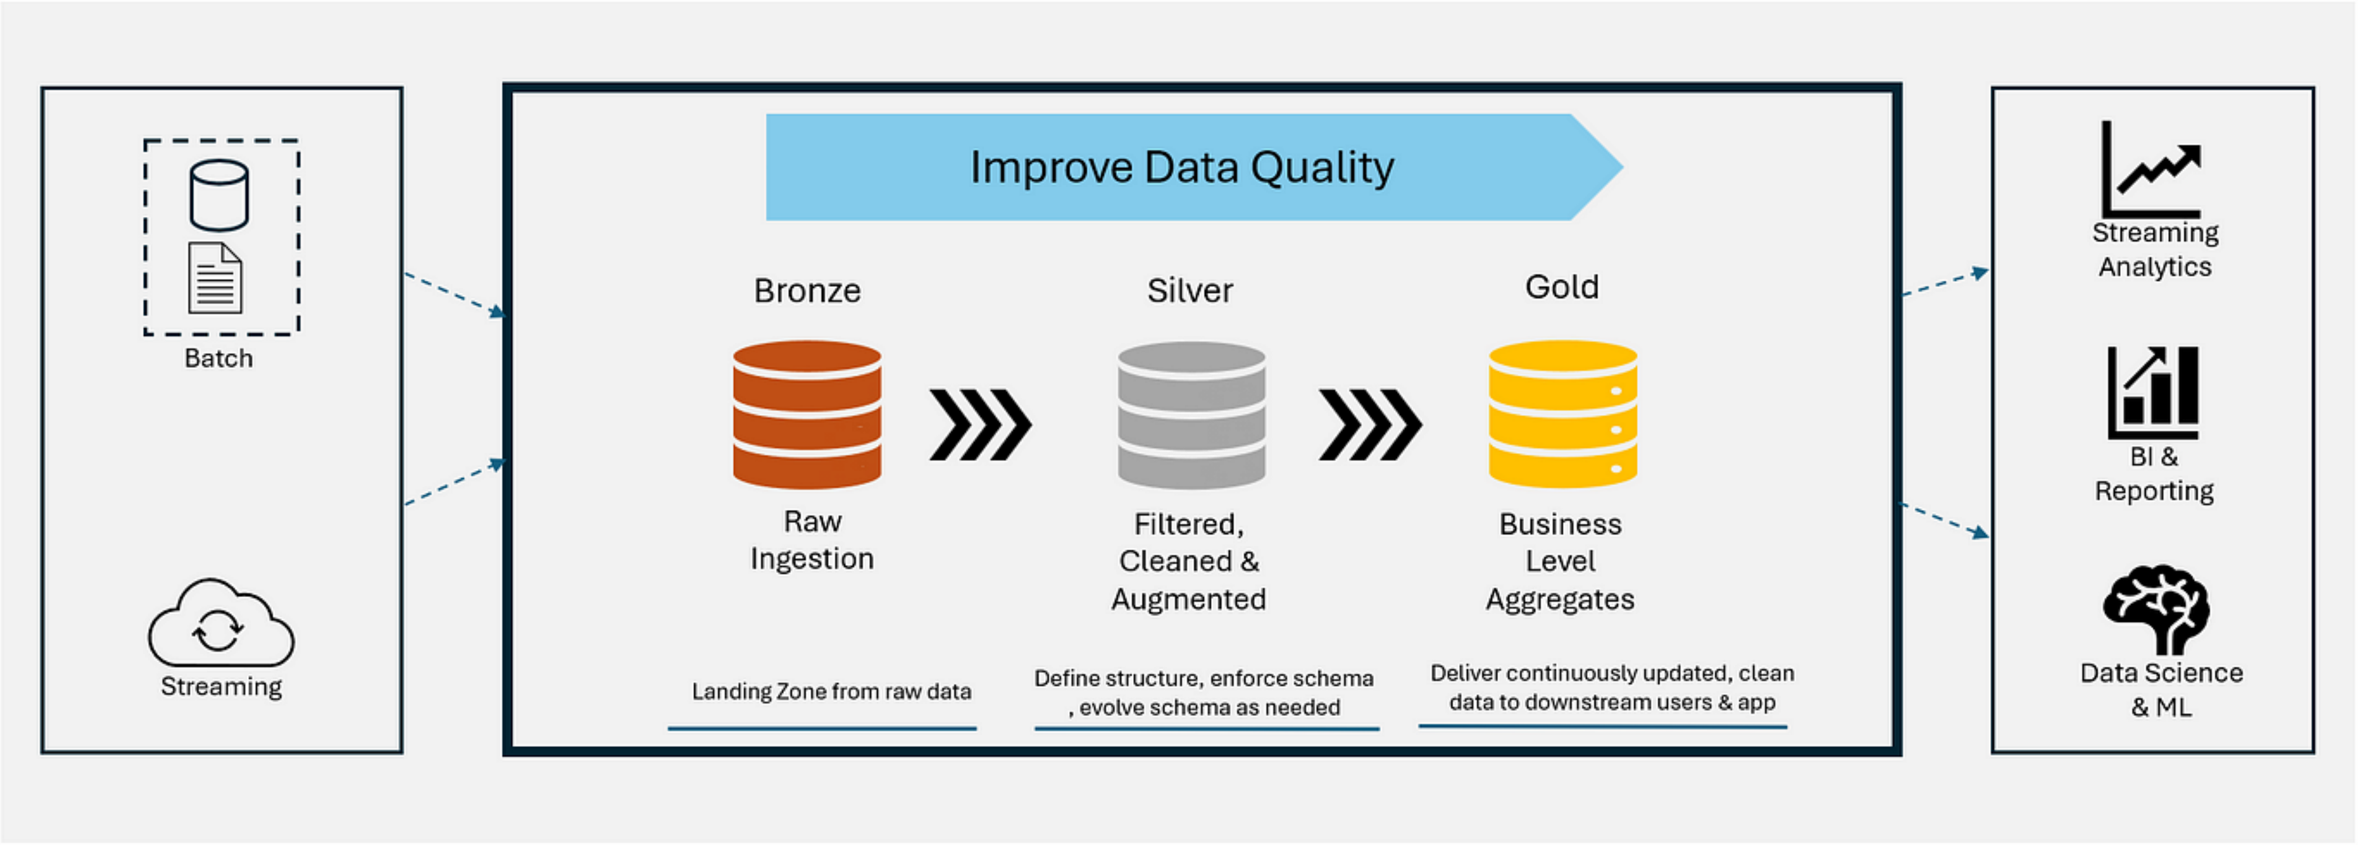

Что такое (Data **Lake** + Data Ware**house** = **Lakehouse)**

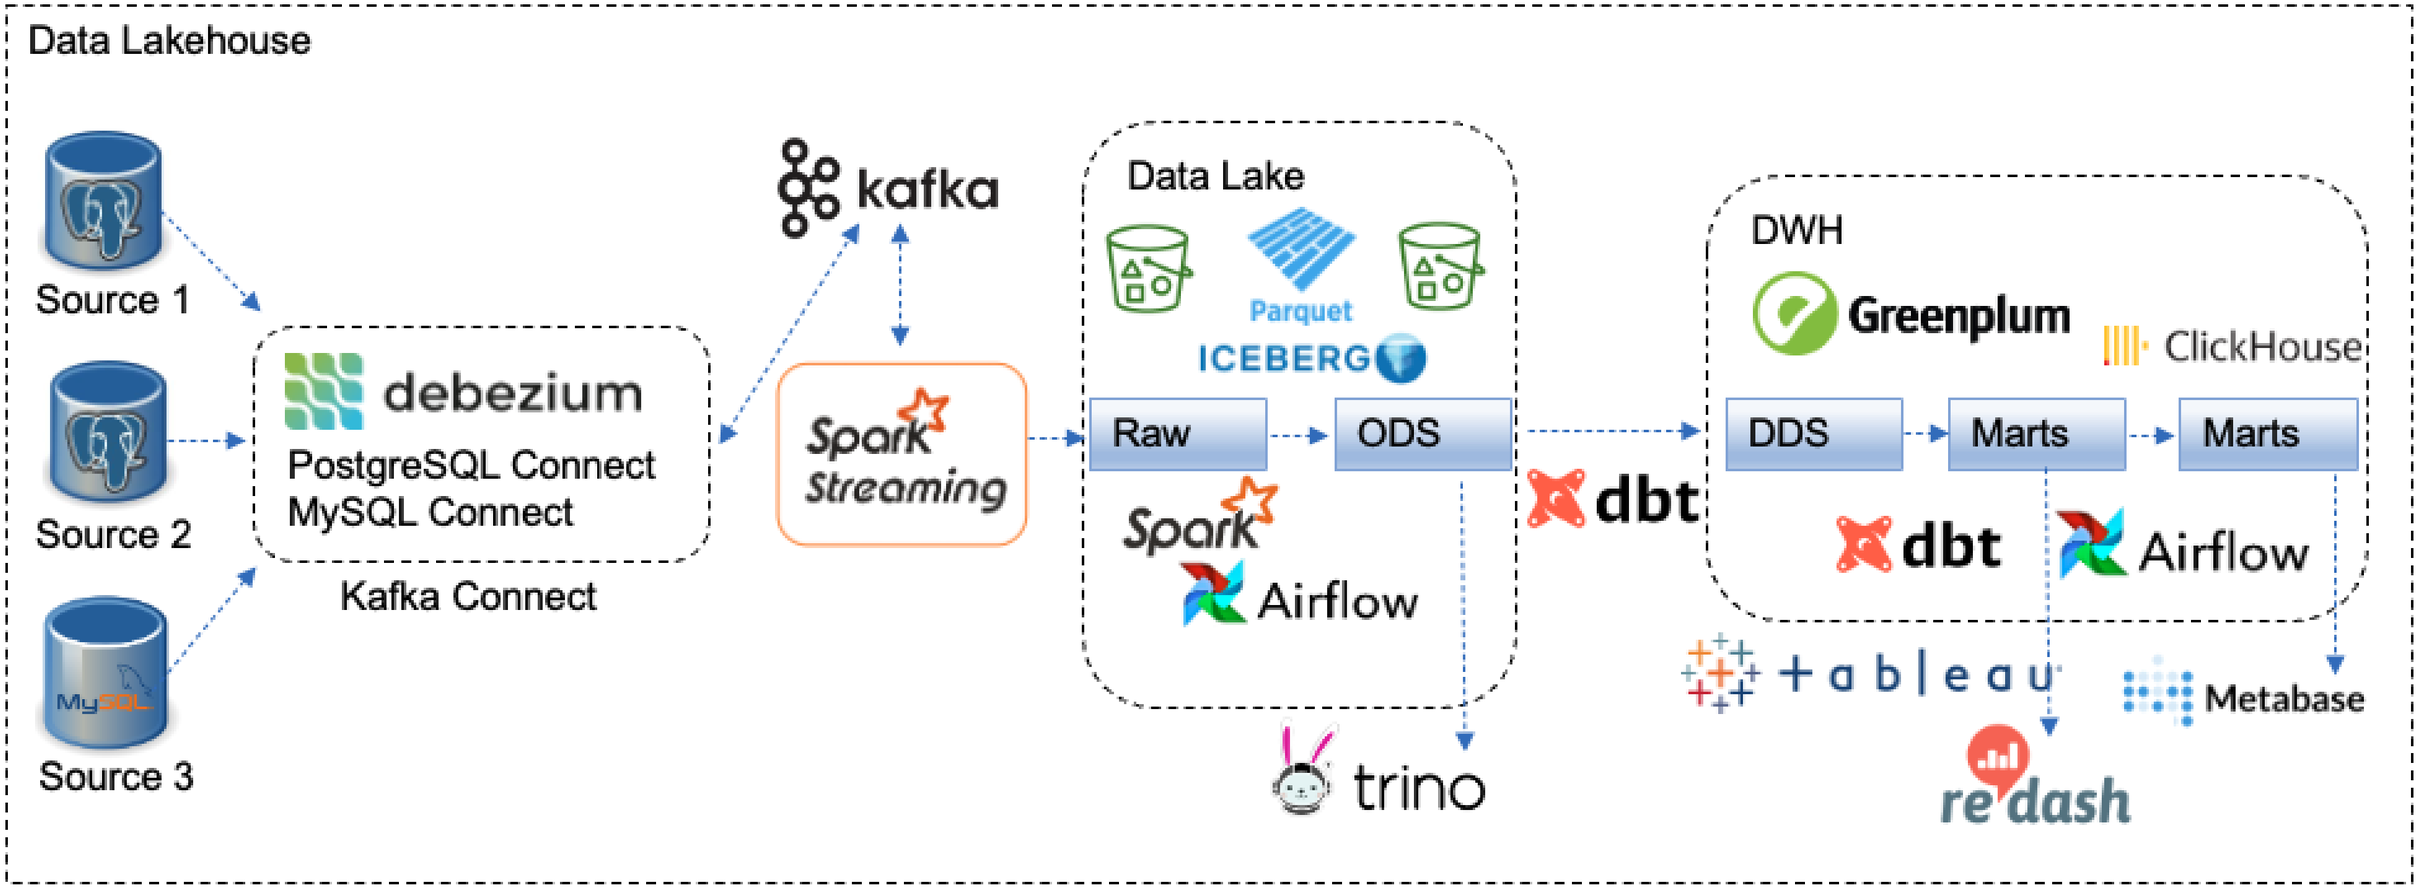

Gartner Data Management Hype Cycle

Hype – шумиха

Инновационный триггер

Пик раздутых ожиданий

Долина разочарования

Склон просветления

Плато продуктивности

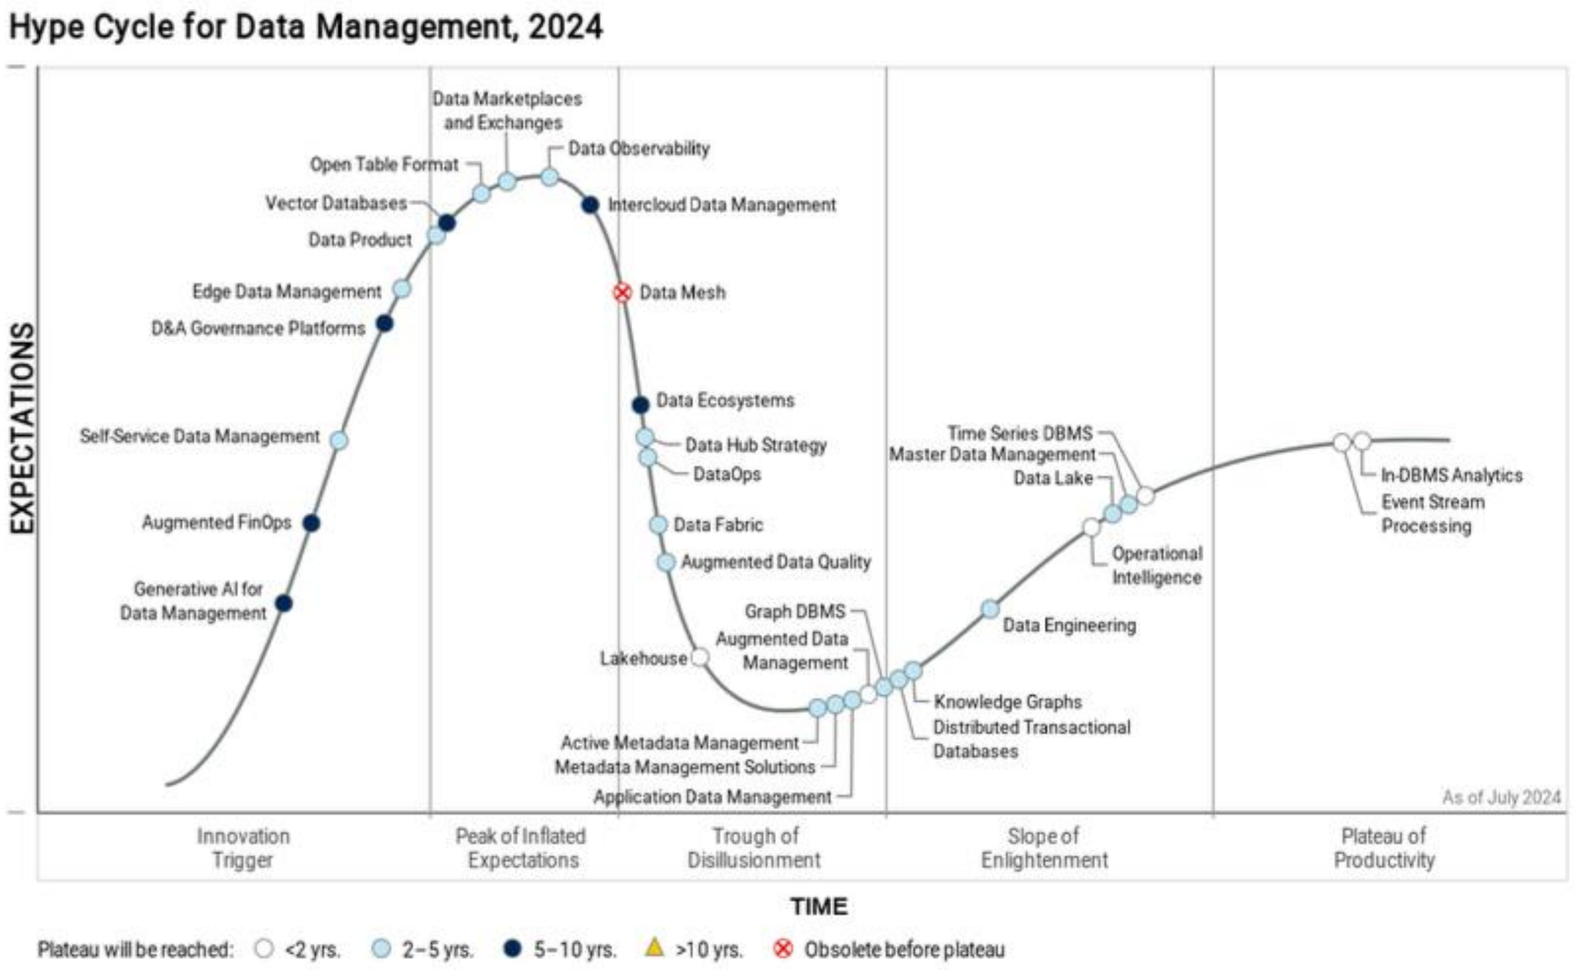

Gartner

Data Management

- **GenAI стал "невидимой рукой" всех инноваций**
  - **AI-Ready Data** (новинка 2025 и сразу на пике)
  - **Augmented Data Management**
  - **Augmented FinOps**
- **Lakehouse стал мейнстрим-архитектурой**
  - **Lakehouse Architecture** - единая платформа
  - **Open Table Format** - остается на пике второй год
  - **Lakehouse** – проверенная архитектура
- **Data Product побеждает Data Mesh**
  - **Data Product** перешел на максимальный хайп
  - **Data Contracts** - формальное обязательство производителя данных предоставить Продукт данных, соответствующий определенной структуре, формату и уровню качества (SLA)
  - **Data Marketplaces** - обеспечивают ликвидность
- **Графовые технологии** наконец "выстрелили”
- **Наступает Эра платформенной консолидации**
  - **Data Management Platforms**
  - **Data Ecosystems** - целостные среды
  - **Event Stream Processing** - зрелая технология для обработки данных в режиме реального времени.

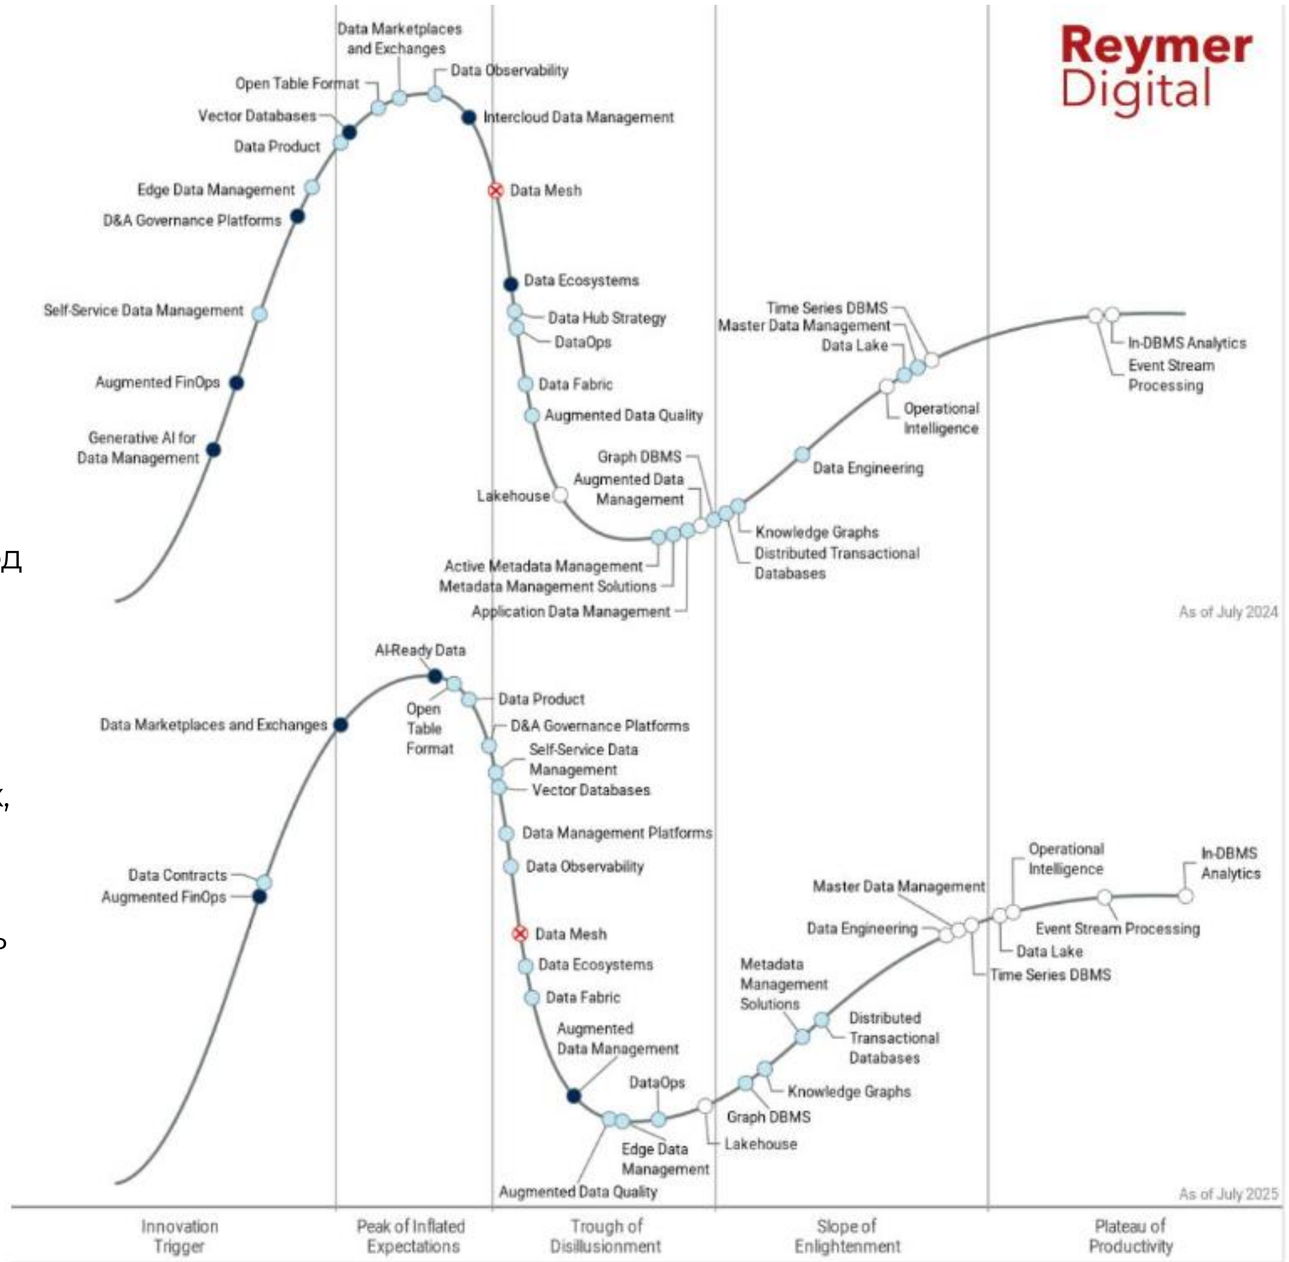

Итоги

- Наука о данных
- Разделение специализаций
- Инженер данных
- Хранилища данных

Стажировка в Т-банк

Аналитика, Разработка, Тестирование

Т-Старт

Кому подойдет стажировка

Студентам и начинающим специалистам, которые хотят начать карьеру в бигтехе и готовы уделять работе от 20 часов в неделю

- **Возможность совмещать с учебой**
- **Удобный формат**
- **Комьюнити и развитие**
- **Удобный офис в Екатеринбурге**

Сайт Т-Образования

ТГ-канал Т-Образования

best-talents@tbank.ru

Т-Банк — финансовая онлайн-экосистема, объединяющая полный спектр финансовых услуг для частных лиц и бизнеса

Бонус. Экономика впечатлений

Потребитель платит за эмоции и за трансформационный опыт, который он переживает в связи с потреблением того или иного товара и услуги
В общей сложности объем глобальной экономики
впечатлений составляет порядка **$6,5 трлн** и растет с темпом **3%** в год

Источник: Джозеф Пайн и Джеймс Гилмор, «Добро пожаловать в экономику впечатлений», Harvard Business Review, 1998